Do Som ao Sucesso: Uma Abordagem de Machine Learning à Popularidade Musical no Spotify

Daniela Saad
Instituto Universitário de Lisboa (ISCTE-IUL)
Portugal

Abstract

Com o crescimento das plataformas de streaming, a indústria musical passou a dispor de um volume crescente de dados quantitativos sobre as características das faixas e o comportamento dos ouvintes. Este estudo investiga em que medida as características de áudio — em particular a valência emocional — influenciam a popularidade musical no Spotify, e explora os padrões que emergem na análise de artistas, músicas e perfis de ouvintes nos géneros pop, hip-hop e rock. Para tal, foi utilizado um dataset de 15 159 faixas, seguindo a metodologia CRISP-DM e combinando estatística inferencial, modelação preditiva supervisionada, análise exploratória e clustering não supervisionado. A normalidade da variável valência foi testada através do teste de Shapiro-Wilk, confirmando a sua ausência e justificando a aplicação do teste de Kruskal-Wallis com subsampling equilibrado de 100 observações por grupo. Os resultados não revelaram uma relação estatisticamente significativa entre a valência emocional e os níveis de popularidade ($p = 0{,}397$), conduzindo à não rejeição da hipótese nula e confirmada por uma correlação de Pearson de $r = 0{,}043$. Em contraste, um modelo Support Vector Classifier (SVC) treinado com a variável derivada *artist_avg_pop* atingiu uma acurácia de 81,13%, demonstrando que o historial de popularidade do artista constitui um preditor significativamente mais robusto do sucesso comercial de uma faixa do que as suas propriedades acústicas intrínsecas. A análise exploratória por género revelou que o pop apresenta os valores medianos de popularidade mais elevados, com destaque para Masked Wolf, Doja Cat e Billie Eilish como líderes nos géneros pop, hip-hop e rock, respetivamente. Por fim, a segmentação por K-Means ($k = 6$) identificou seis perfis de ouvinte comportamentalmente distintos — Acústica, Energia ao Vivo, Instrumental, Pop, Hip-Hop e Rock — validados pela maximização do *Silhouette Score* (0,1725) e pela projeção bidimensional em PCA. Estes resultados contribuem para a literatura de análise musical orientada por dados e oferecem implicações práticas para plataformas de streaming e agentes da indústria musical.

Permission to make digital or hard copies of part or all of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for third-party components of this work must be honored. For all other uses, contact the owner/author(s).

© 2026 Copyright held by the owner/author(s).

Keywords: valência, popularidade da música, machine learning

Reference Format:
Daniela Saad. 2026. Do
Som ao Sucesso: Uma Abordagem de Machine Learning à Popularidade Musical no Spotify. In *Proceedings of ACM Conference (Conference'17).* 16 pages.

1 Introdução

Com o crescimento das plataformas de streaming, o volume de dados gerados na indústria musical aumentou de forma exponencial. O Spotify, um dos serviços de streaming mais utilizados a nível mundial, disponibiliza não só acesso a milhões de faixas, mas também um conjunto rico de descritores quantitativos — os *audio features* — que caracterizam cada música em dimensões como a dançabilidade, a energia, a valência e a acústica. A análise destas métricas permite explorar não apenas as preferências gerais dos utilizadores, mas também identificar e prever quais as características que contribuem para o sucesso de uma faixa através de modelos preditivos.

Enquanto abordagens tradicionais dependiam do julgamento de especialistas ou do desempenho em tabelas de vendas, a disponibilidade de dados de streaming em larga escala possibilitou metodologias orientadas pelos dados, capazes de examinar sistematicamente a relação entre as propriedades de uma faixa e a sua popularidade. Trabalhos anteriores demonstraram que os *audio features* constituem aproximações válidas às dimensões emocionais da música ([6]; [3]; [4]), e que modelos de *machine learning* podem utilizar essas características para prever a popularidade com níveis de precisão relevantes ([7]; [5]), embora os resultados variem consoante o *dataset* e a metodologia adotada.

Apesar destes avanços, poucos estudos analisam simultaneamente a dimensão emocional, a previsão de popularidade segmentada por género musical e a perfilagem de ouvintes num único *dataset* de streaming. A maioria dos trabalhos centra-se exclusivamente na previsão baseada em áudio — ignorando fatores sociais e contextuais — ou trata a popularidade como variável contínua, limitando a interpretabilidade dos resultados. Adicionalmente, a interação entre género musical, perfil emocional e segmentação de ouvintes permanece pouco explorada na literatura.

O presente trabalho procura colmatar estas lacunas, colocando a seguinte questão de investigação: Em que medida

as características de uma faixa - em particular a valência - influenciam a sua popularidade, e que padrões emergem quando se analisam artistas, músicas e perfis de ouvintes nos géneros pop, hip-hop e rock?

O *dataset* utilizado é composto por 15 159 faixas musicais distribuídas por três géneros — rock, pop e hip-hop — permitindo explorar as relações entre popularidade e características técnicas das músicas.

Neste contexto, torna-se relevante compreender o impacto do estado emocional transmitido por uma música na sua receção pelo público. Assim, a pergunta de investigação inclui a análise da influência da valência na popularidade. Para orientar esta análise e permitir uma validação estatística posterior, foram definidas as seguintes hipóteses:

- **Hipótese Nula (H_0):** A distribuição da valência das músicas é igual em todos os níveis de popularidade.
- **Hipótese Alternativa (H_1):** A distribuição das músicas é significativamente diferente em pelo menos um dos níveis de popularidade.

Para testar estas hipóteses, foi aplicado o teste não-paramétrico de Kruskal-Wallis, adequado para comparar distribuições entre três grupos independentes — neste caso, as categorias de popularidade *baixa*, *média* e *alta* — sem assumir a normalidade da distribuição, condição verificada através da análise visual do histograma e do *Q-Q plot* da variável *valence* e pelo teste de Shapiro-Wilk. Como procedimento integrado no desenho do teste, recorreu-se a uma técnica de *subsampling* equilibrado, extraindo-se aleatoriamente 100 observações de cada grupo, de forma a evitar o fenómeno de *large-sample bias*, comum em bases de dados de grande dimensão, onde qualquer diferença mínima se torna estatisticamente significativa, independentemente da sua relevância prática.

Para responder à problemática e cumprir os requisitos metodológicos, foram estabelecidos os seguintes objetivos específicos:

- **Testar a hipótese formulada:** Avaliar a relação entre valência e popularidade através de um teste não-paramétrico de Kruskal-Wallis com *subsampling* equilibrado, complementado por um estudo de correlação e análise visual da distribuição das categorias de popularidade através de diagramas de extremos e quartis (*boxplots*).
- **Modelação preditiva:** Desenvolver e comparar modelos de classificação supervisionada capazes de prever a popularidade de uma música, quantificando o contributo das variáveis numéricas.
- **Análise exploratória:** Mapear os artistas mais célebres e as suas músicas, compreendendo a consistência do seu sucesso no mercado.
- **Segmentação por *clustering*:** Identificar diferentes perfis de ouvintes com base nas características das faixas consumidas, utilizando o algoritmo K-Means.

Por fim, para garantir uma leitura clara e organizada, o relatório encontra-se estruturado de acordo com as etapas sequenciais da investigação. O estudo prossegue quatro objetivos principais: (1) analisar a correlação entre os *audio features* - em particular a valência - e a popularidade musical, testando estatisticamente, através do teste não-paramétrico de Kruskal-Wallis com *subsampling* equilibrado, se a distribuição da valência difere entre os diferentes níveis de popularidade; (2) desenvolver e comparar modelos de classificação supervisionada capazes de prever a popularidade; (3) realizar uma análise exploratória dos artistas e músicas mais populares por género; e (4) segmentar as faixas em perfis de ouvinte distintos através do algoritmo K-Means, revelando padrões latentes nas características dos diferentes géneros.

2 Revisão da Literatura

2.1 Emoção da Música

A compreensão das emoções musicais tem as suas raízes no modelo circumplexo do afeto proposto por [6], que demonstrou que os estados emocionais não são independentes entre si, mas sim altamente correlacionados, organizando-se em torno de dois eixos fundamentais: a valência (prazer vs. desagrado) e a excitação (ativação vs. calma). Esta framework bidimensional tornou-se a base teórica dominante para o estudo da emoção em contextos musicais, permitindo mapear de forma sistemática a resposta afetiva do ouvinte.

Com o surgimento de plataformas de streaming, tornou-se possível operacionalizar estes conceitos em grande escala. Estudos recentes têm utilizado os audio features do Spotify, nomeadamente a valência, a energia e a dançabilidade, como proxies computacionais das dimensões emocionais identificadas por [6]. [4] demonstraram que a energia e a dançabilidade são os fatores mais determinantes para o tom emocional de uma composição, identificando, ainda, uma tendência histórica para sonoridades progressivamente mais energéticas a partir da década de 1960. De forma complementar, [3]) revelaram que estas propriedades técnicas do som se ligam a objetivos psicológicos e sociais concretos, nomeadamente a regulação do humor, sendo a música com níveis superiores de valência e energia a que mais incentiva o movimento e o envolvimento emocional do ouvinte.

Em conjunto, estes estudos sugerem que os audio features do Spotify constituem uma aproximação válida ao estado emocional transmitido pela música, justificando a sua utilização como variáveis centrais na análise da relação entre emoção e popularidade musical desenvolvida neste trabalho.

2.2 Popularidade Musical e Audio Features

A previsão da popularidade musical tem ganho crescente atenção na literatura de ciência de dados, impulsionada pela disponibilidade de dados de streaming em larga escala. Vários estudos têm explorado em que medida as características técnicas do áudio permitem antecipar o sucesso comercial de

uma faixa, com resultados que revelam tanto o potencial como as limitações desta abordagem.

Utilizando exclusivamente audio features do Spotify, [7] demonstrou que atributos como o volume, a duração e a data de lançamento são preditores relevantes de popularidade, alcançando uma acurácia de 69% com um modelo de Random Forest. De forma semelhante, [5] desenvolveram o SpotiPred, um sistema de previsão baseado em Random Forest treinado com mais de 170.000 faixas, atingindo uma acurácia de 95,37%. Estes resultados sugerem que os audio features encerram informação preditiva relevante, ainda que o desempenho dos modelos varie consideravelmente consoante o dataset e a metodologia utilizados.

Um estudo particularmente relevante para contextualizar o presente trabalho é o de [8], que compararam a capacidade preditiva de modelos treinados apenas com audio features do Spotify face a modelos que incorporam adicionalmente características de redes sociais provenientes do YouTube. Os resultados demonstraram que a inclusão de variáveis sociais melhorou a precisão entre 10% e 60%, com o Random Forest a destacar-se como o modelo mais robusto, atingindo 79,6% de acurácia. Esta evidência indica que os audio features, por si só, capturam apenas parcialmente os fatores que determinam o sucesso de uma música, sendo a dimensão social um complemento relevante que escapa à análise exclusivamente acústica.

Uma limitação comum a estes estudos reside na dependência exclusiva de métricas de áudio, que ignoram fatores contextuais com impacto comprovado na popularidade, como a promoção em redes sociais, a notoriedade prévia do artista ou o momento de lançamento [8]. Adicionalmente, a variabilidade dos resultados entre estudos, com acurácias que oscilam entre 69% de [7] e 95% de [5], sugere que o desempenho preditivo é altamente sensível à composição do dataset e às escolhas metodológicas, o que dificulta a generalização das conclusões.

2.3 Machine Learning em Classificação Musical

A aplicação de algoritmos de aprendizagem automática à música tem uma trajetória consolidada na literatura, com especial ênfase na classificação de géneros e na identificação de padrões sonoros. Esta investigação fornece a base metodológica para o presente trabalho, justificando as escolhas de modelação adotadas.

Neste domínio, [1] realizou uma comparação sistemática entre técnicas de deep learning e modelos tradicionais de ML para classificação de géneros musicais, concluindo que abordagens ensemble oferecem o desempenho mais robusto. Ainda assim, o autor demonstrou que classificadores como o Random Forest e o SVM apresentam resultados competitivos quando aplicados a características extraídas manualmente, o que valida a sua utilização em contextos onde a interpretabilidade do modelo é prioritária. Numa perspetiva de maior escala, [2] aplicaram Random Forest a um dataset com dez géneros musicais distintos, alcançando 90% de precisão e confirmando a superioridade deste algoritmo face a alternativas como Naïve Bayes e Árvores de Decisão simples.

Em conjunto, estes estudos fundamentam a escolha do Random Forest como modelo de referência no presente trabalho, não apenas pela sua precisão demonstrada em contextos musicais, mas também pela sua capacidade de lidar com dados heterogéneos e de fornecer métricas de importância das variáveis, permitindo interpretar quais os audio features com maior poder preditivo.

Para além dos métodos de classificação supervisionada, a literatura tem igualmente explorado técnicas de aprendizagem não supervisionada para segmentar músicas em perfis distintos. O algoritmo K-Means destaca-se neste contexto pela sua simplicidade interpretativa e eficiência computacional, sendo frequentemente aplicado em conjunto com métricas de validação, como o método Elbow e o Silhouette Score, para determinar o número ótimo de clusters [2]. Essa abordagem complementa a classificação supervisionada ao permitir identificar agrupamentos naturais nos dados, sem recorrer a variáveis-alvo predefinidas, revelando padrões latentes nas características acústicas das faixas musicais.

2.4 Síntese

A literatura revisada evidencia três contributos centrais para o presente trabalho: a valência e a excitação como dimensões emocionais operacionalizáveis através dos audio features do Spotify ([6];[3]; [4];) a capacidade preditiva limitada, mas real, desses atributos na previsão de popularidade ([7]; [5];[8]); e a robustez do Random Forest em tarefas de classificação musical ([1]; [2]). Apesar destes avanços, poucos estudos analisam simultaneamente a dimensão emocional e a previsão de popularidade segmentada por género num único dataset de streaming, lacuna que este trabalho procura resolver, combinando métodos supervisionados de classificação com uma análise de clustering não supervisionada para identificar perfis de ouvinte distintos.

3 Métodos

3.1 Metodologia

Neste trabalho foi utilizada a metodologia CRISP-DM (*Cross Industry Standard Process for Data Mining*), amplamente adotada em projetos de análise de dados e *Machine Learning*, permitindo estruturar o processo de forma organizada e sistemática.

As seguintes fases foram aplicadas:

3.1.1 Business Understanding. Nesta fase inicial, procedeu-se à contextualização e definição formal dos objetivos primordiais deste estudo. Com o intuito de direcionar a investigação e delimitar o âmbito da análise de dados, formularam-se as seguintes questões de investigação:

- **Questão de Investigação 1:** Em que medida a predominância de estados emocionais nas músicas se correlaciona com o nível de popularidade alcançado pelas respetivas obras?
- **Questão de Investigação 2:** Quais os artistas ou bandas que, no contexto de cada género musical, registam os maiores níveis de consumo, tomando como referência os principais indicadores de popularidade de mercado?

3.1.2 Data Understanding. Nesta fase, procedeu-se à exploração inicial do conjunto de dados (*dataset*) com o objetivo de compreender a sua estrutura e principais características. Inicialmente, aferiu-se a tipologia dos dados de cada atributo e determinou-se a dimensão da base de dados, a qual é constituída por 15 159 observações (linhas) e 23 variáveis (colunas).

Subsequentemente, realizou-se a análise estatística descritiva das variáveis numéricas — contemplando métricas como valores mínimos, máximos e médias de atributos como *Popularity*, *danceability*, *energy*, *key*, *loudness*, *mode*, *speechiness*, *acousticness*, *instrumentalness*, *liveness*, *valence*, *tempo*, *duration_ms* e *time_signature* — procedendo-se igualmente à inspeção dos registos contidos nas variáveis categóricas (como *Genres*, *genre*, *uri*, *track_href* e *analysis_url*), de forma a compreender a natureza e o contexto dessas informações.

Num segundo momento, examinou-se a distribuição de todas as variáveis numéricas através de histogramas, permitindo observar a dispersão, o comportamento dos dados, os padrões gerais e a frequência dos valores. Dedicou-se especial atenção à variável *popularity*, variável dependente (*target*) do presente estudo, através da construção de um histograma específico para a sua análise isolada.

Por fim, calculou-se a popularidade média por género musical, cuja distribuição foi complementada visualmente através de diagramas de extremos e quartis (*boxplots*) e de gráficos de barras.

3.1.3 Data Preparation. No âmbito da preparação e do tratamento dos dados, foram implementadas diversas operações estruturais que englobaram processos de limpeza, validação e transformação do conjunto de dados.

O ponto de partida consistiu na verificação da existência de valores duplicados e de dados omissos (nulos). A inspeção preliminar não revelou inconsistências relevantes nem valores em falta que comprometessem a integridade do conjunto de dados.

Subsequentemente, com o objetivo de assegurar a uniformidade e a consistência textual, removeu-se a formatação de listas (os caracteres de parênteses retos `[ ]`) na coluna *Genres*.

Por último, realizou-se a limpeza e filtragem da coluna *genre*: removeram-se os caracteres residuais e os espaços em branco em excesso e, em seguida, aplicou-se um filtro para reter exclusivamente as observações correspondentes aos géneros de interesse para o estudo (*hiphop*, *rock* e *pop*), eliminando quaisquer outros registos irrelevantes ou inconsistentes.

3.1.4 Modeling. No âmbito da fase de modelação da metodologia CRISP-DM, foram delineadas as estratégias analíticas, estatísticas e computacionais para responder às questões de investigação propostas, englobando testes estatísticos inferenciais, algoritmos de aprendizagem supervisionada e técnicas de agrupamento não supervisionado.

Para abordar a primeira questão, relativa ao impacto da predominância dos estados emocionais no sucesso das faixas, a variável contínua dependente *Popularity* foi discretizada numa variável categórica ordinal através do método de intervalos (*binning*), estruturando-se três níveis de consumo: *Baixa* (0–40), *Média* (40–70) e *Alta* (70–100).

Previamente à aplicação de testes de comparação, validou-se a distribuição da variável independente *Valence* através de um histograma e um gráfico quantil-quantil (*Q-Q Plot*), análise complementada formalmente pelo teste de Shapiro-Wilk. Face à ausência de uma distribuição normal nos dados, optou-se pela aplicação do Teste de Kruskal-Wallis, uma abordagem não-paramétrica robusta para testar se a distribuição da valência é idêntica entre os três grupos (H_0) ou se difere estatisticamente em pelo menos um deles (H_1).

Como procedimento integrado no desenho de teste, utilizou-se uma técnica de *subsampling* equilibrado, extraindo-se aleatoriamente 100 observações de cada grupo com recurso à fixação de um critério de replicabilidade.

Esta análise estatística foi complementada por um estudo de correlação bivariada e pela construção de uma matriz de correlação, sendo o comportamento e a distribuição dos grupos suportados visualmente através de gráficos de caixas (*boxplots*).

A investigação prosseguiu para o desenvolvimento de modelos preditivos de aprendizagem supervisionada para identificar os principais determinantes da popularidade. Inicialmente, calculou-se a correlação linear das variáveis numéricas com o alvo e ajustou-se um modelo de Regressão Linear Múltipla.

Posteriormente, o conjunto de dados foi segmentado na proporção de 80% para treino e 20% para teste. Na fase de pré-processamento, as variáveis categóricas *Artist Name*, *genre* e *Genres* foram convertidas para formatos numéricos e criaram-se duas novas métricas por engenharia de atributos: a *intensity* (combinação de *Energy* e *Loudness*) e a *artist_avg_pop* (média de popularidade das músicas de cada artista).

O fluxo preditivo envolveu o treino dos algoritmos *K-Nearest Neighbors* (KNN), *Gradient Boosting*, Árvores de Decisão, *Random Forests* e Máquinas de Vetores de Suporte (*Support Vector Classifier* – SVC). A análise exploratória e a interpretação visual dos dados foram complementadas através de *boxplots* e *pairplots*.

Foram testadas diferentes combinações de variáveis explicativas ao longo do processo de modelação. O modelo *Support Vector Classifier* (SVC) apresentou o melhor desempenho preditivo quando treinado com a variável derivada *artist_avg_pop* como principal preditor da categoria de popularidade, avaliando-se o seu desempenho através de uma matriz de confusão aplicada exclusivamente aos 20% dos dados reservados para teste.

Por fim, de modo a responder à segunda questão de investigação sobre os líderes de consumo por género, realizou-se uma análise exploratória baseada em gráficos de barras, diagramas de "chupa-chupa" (*lollipop charts*) e barras de erro.

Para aprofundar a identificação de padrões, aplicou-se o algoritmo de aprendizagem não supervisionada K-Means para segmentar as faixas em perfis homogéneos. Como pré-processamento, as variáveis explicativas foram normalizadas via *StandardScaler*.

O número ótimo de *clusters* (k) foi determinado de forma combinada através do Método do Cotovelo (*Elbow Method*) e do Índice de Silhueta (*Silhouette Score*), optando-se pela maximização deste último.

A caracterização e validação visual dos agrupamentos resultantes foram realizadas com o suporte dos gráficos de *Elbow* e *Silhouette Score*, gráficos de radar para os centroides, distribuições de géneros por perfil e uma projeção bidimensional baseada na Análise de Componentes Principais (PCA).

3.1.5 Evaluation. Nesta fase procedeu-se à análise crítica dos resultados obtidos face aos objetivos de investigação delineados inicialmente. O foco incidiu na interpretação das métricas de desempenho dos modelos estatísticos, preditivos e de agrupamento, garantindo a robustez científica antes da fase de implementação.

No que concerne à primeira questão de investigação, a avaliação do Teste de Kruskal-Wallis revelou um *p-value* de 0.397. Dado que este valor se posiciona substancialmente acima do nível de significância padrão de 5% ($\alpha = 0.05$), determinou-se a não rejeição da hipótese nula (H_0).

O mapeamento visual através dos *boxplots* corroborou esta conclusão, evidenciando medianas e distribuições de valência sobrepostas entre os três níveis de popularidade. Complementarmente, a matriz de correlação linear indicou a ausência de uma associação bivariada relevante entre o estado emocional e o sucesso da faixa.

Conclui-se, portanto, que a valência isolada não é um fator determinante para ditar a popularidade de uma música no contexto analisado

Face a este resultado, a avaliação estendeu-se aos modelos de aprendizagem supervisionada para apurar quais as variáveis que efetivamente influenciam o consumo. O modelo *Support Vector Classifier* (SVC), selecionado para a validação final, foi submetido a um teste rigoroso sobre os 20% dos dados reservados independentemente para esta etapa.

O modelo alcançou uma métrica de precisão global (*accuracy*) de 81.13%, o que reflete uma elevada capacidade preditiva. A análise detalhada da matriz de confusão permitiu diagnosticar o comportamento do classificador: o algoritmo demonstrou uma performance robusta na identificação das classes "Média" (com 1400 verdadeiros positivos) e "Baixa" (770 acertos), embora tenha evidenciado uma tendência de sobreposição ao classificar faixas de popularidade "Alta", gerando um volume significativo de falsos negativos ao confundi-las com a classe média.

Esta avaliação demonstrou que a notoriedade histórica calculada na variável *artist_avg_pop* possui maior capacidade preditiva do que a valência emocional no mapeamento do sucesso comercial.

Por fim, a resposta à segunda questão de investigação foi validada de forma cruzada entre a análise macro descritiva e a modelação não supervisionada sobre as 15 159 faixas.

A nível descritivo, isolaram-se os líderes de popularidade por género, com destaque para Doja Cat no hip-hop (*Kiss Me More*), Masked Wolf no pop (*Astronaut In The Ocean*) e Billie Eilish no rock (*Your Power*).

Complementarmente, a avaliação do algoritmo K-Means confirmou a seleção de $k = 6$ *clusters* como a estrutura ótima para o espaço de estados de 9 atributos, fundamentada matematicamente pela maximização do Índice de Silhueta para 0.1725 e pela minimização do índice Davies-Bouldin para 1.5837.

A segmentação originou perfis comportamentais claros, liderados quantitativamente pelo perfil Pop (4632 faixas; 30.6%) e pelo perfil Rock (4061 faixas; 26.8%), ambos dominados maioritariamente por músicas do género rock, seguidos pelos perfis de Acústica (2435 faixas, com dominância de pop), Hip-Hop (1804 faixas), Energia ao Vivo (1302 faixas) e Instrumental (925 faixas).

Esta distribuição, validada visualmente pela a *Análise de Componentes Principais* (PCA), sugeriu que o modelo reflete com precisão as dinâmicas reais do mercado, mapeando com rigor os géneros dominantes em cada nicho estratégico de consumo.

3.1.6 Deployment. A fase de *deployment* traduz os resultados obtidos em recomendações estratégicas para o mercado musical e plataformas de distribuição digital, focando-se na transferência de conhecimento para a tomada de decisão:

- **Estratégia de Marketing:** Os resultados do modelo SVC demonstram que as editoras não devem focar os recursos na valência emocional (*valence*) para prever o sucesso de uma faixa. Em vez disso, os investimentos devem priorizar o desenvolvimento da notoriedade de base do artista (*artist_avg_pop*), variável que demonstrou maior capacidade preditiva associada a níveis elevados de popularidade.
- **Segmentação:** Os 6 perfis comportamentais identificados pelo K-Means funcionam como uma ferramenta

operacional para plataformas de *streaming* e curadores. Estes perfis permitem otimizar a criação de *playlists* temáticas e direcionar campanhas publicitárias altamente segmentadas baseadas nos nichos de consumo validados.
- **Manutenção do Modelo:** Dada a volatilidade das tendências musicais, recomenda-se a alimentação e o reajuste periódico dos modelos com novas extrações de dados do Spotify, garantindo que as soluções desenvolvidas mantenham a sua utilidade prática a longo prazo.

3.2 Fonte de Dados

O dataset utilizado neste trabalho denomina-se *Spotify Multi-Genre Playlists Data* e foi obtido através da plataforma Kaggle, contendo informações extraídas do Spotify relativas a faixas musicais, artistas e características de áudio.

Este dataset é composto por sete ficheiros CSV correspondentes a diferentes géneros musicais presentes em playlists do Spotify. Para o desenvolvimento deste projeto, foram selecionados três ficheiros: *pop_music_data.csv*, *hiphop_music_data.csv* e *rock_music_data.csv*.

A seleção dos géneros pop, rock e hiphop deve-se à elevada representatividade destas categorias no conjunto de dados e à sua relevância no contexto do consumo musical contemporâneo nas plataformas de streaming.

Após a seleção, os ficheiros foram combinados num único dataset, designado *music_data_combined.csv*, com recurso a uma ferramenta de apoio (Claude), de forma a permitir uma análise integrada dos diferentes géneros musicais.

O dataset final é composto por 23 variáveis (colunas) e 15 159 observações (linhas).

3.2.1 Descrição das Variáveis. Foi realizada uma análise ao conteúdo de cada variável, de forma a compreender o seu significado e interpretação no contexto do dataset:

- **Artist Name**: nome do artista
- **Track Name**: nome da música
- **Popularity**: utilizada como variável dependente do estudo, corresponde à métrica de popularidade disponibilizada pelo Spotify, variando entre 0 e 100.
- **Genres**: conjunto de géneros associados à música
- **Genre**: género principal da música
- **Playlist**: playlist do Spotify à qual a música pertence
- **Danceability**: variável com valores entre 0 e 1 que indica o grau de adequação da música para dança
- **Energy**: variável entre 0 e 1 que representa a intensidade e atividade da música
- **Key**: variável discreta entre 0 e 11, correspondente ao tom musical (ex.: Dó, Ré, Mi, etc.)
- **Loudness**: medida em decibéis (normalmente com valores negativos), que representa o volume da música
- **Mode**: variável entre 0 e 1 que indica o tipo de tonalidade
- **Speechiness**: variável entre 0 e 1 que indica a quantidade de fala presente na música
- **Acousticness**: variável entre 0 e 1 que indica a acústica na música
- **Instrumentalness**: variável entre 0 e 1 que indica se a música é instrumental (sem voz)
- **Liveness**: variável entre 0 e 1 que indica se a música foi gravada ao vivo
- **Valence**: representa uma medida computacional do estado emocional da música, assumindo valores próximos de 1 para faixas consideradas mais positivas, alegres ou eufóricas, e valores próximos de 0 para músicas associadas a emoções mais negativas ou melancólicas.
- **Tempo**: velocidade da música, medida em BPM (*beats per minute*)
- **Id**: identificador único da música
- **Uri**: identificador interno do Spotify
- **Track_href / Analysis_url**: hiperligações associadas à música
- **Duration_ms**: duração da música, expressa em milissegundos
- **Time_signature**: variável discreta entre 0 e 5 que representa o compasso musical (número de batidas por ciclo)

3.3 Procedimentos e etapas adotadas

O desenvolvimento prático deste estudo seguiu uma abordagem sequencial e iterativa, estruturada em cinco grandes etapas operacionais que traduzem o ciclo de vida dos dados, desde a sua aquisição até à geração de valor estratégico:

1. **Aquisição e Consolidação de Dados:** Obtenção e descarregamento do conjunto de dados secundários diretamente a partir da plataforma *Kaggle*. A base de dados consolidada, composta por 15 159 observações, reúne faixas musicais com os seus respetivos metadados e os descritores quantitativos nativos (*audio features*) disponibilizados originalmente pelo *Spotify*.
2. **Limpeza e Normalização:** Tratamento de texto na coluna *Genres* (remoção de parênteses retos e caracteres residuais) e aplicação de um filtro na variável *genre* para reter exclusivamente as observações de *pop*, *rock* e *hip-hop*, eliminando registos irrelevantes para o âmbito do estudo.
3. **Transformação de Variáveis:** Procedeu-se à discretização da variável dependente *popularity*, transformando-a de contínua para uma variável categórica ordinal dividida em três níveis de consumo: Baixa (0–40), Média (40–70) e Alta (70–100). Adicionalmente, realizou-se a criação de novas métricas explicativas para enriquecer o potencial preditivo dos modelos: a variável *intensity* (através da combinação matemática de *energy* e *loudness*) e a variável *artist_avg_pop* (calculando a média histórica de popularidade de cada artista).

4. **Análise Exploratória e Inferencial:** Avaliação da normalidade da variável *valence* e aplicação do Teste de Kruskal-Wallis, recorrendo a uma técnica de subamostragem (*subsampling*) aleatória e equilibrada (100 observações por grupo) com fixação de um critério de replicabilidade para responder à Questão de Investigação 1.
5. **Modelação Preditiva e Agrupamento:** Segmentação dos dados na proporção de 80% para treino e 20% para teste. Execução de algoritmos supervisionados de classificação (com seleção final do SVC) para prever os níveis de popularidade e aplicação do algoritmo não supervisionado *K-Means* para agrupar o mercado em 6 perfis comportamentais homogéneos, validados por Análise de Componentes Principais (PCA), respondendo à Questão de Investigação 2.

3.4 Ferramentas

Para garantir a consistência, a validação científica da investigação e a máxima eficiência no processamento de grandes volumes de dados, utilizou-se a linguagem de programação *Python*. O ecossistema de desenvolvimento foi suportado por um conjunto de bibliotecas e plataformas especializadas, detalhadas a seguir:

- **Ambiente de Desenvolvimento:** Todo o código foi implementado de forma interativa através do *Jupyter Notebook*. Esta interface foi selecionada pela sua flexibilidade na execução modular do código, organização cronológica das etapas e capacidade de visualização imediata dos resultados intermédios.
- **Manipulação e Processamento de Dados:** Utilizaram-se as bibliotecas *Pandas* e *NumPy*, fundamentais para a limpeza de texto, estruturação matricial dos dados e engenharia de atributos (nomeadamente na criação das métricas *intensity* e *artist_avg_pop*).
- **Análise Estatística:** Recorreu-se ao módulo `stats` da biblioteca *SciPy* para a execução formal dos testes inferenciais não-paramétricos, englobando o teste de normalidade de *Shapiro-Wilk* e o teste de comparação de amostras de *Kruskal-Wallis*.
- **Modelação e *Machine Learning*:** A biblioteca *Scikit-Learn* serviu como pilar central para os fluxos preditivos e de agrupamento. No âmbito do pré-processamento, utilizou-se o módulo `StandardScaler` para a normalização de variáveis e ferramentas de codificação para atributos categóricos. A divisão do *dataset* foi realizada através do módulo `train_test_split` (proporção 80/20). Para a aprendizagem supervisionada, exploraram-se os algoritmos *Decision Tree*, *Random Forest*, *Support Vector Classifier* (SVC), *Gradient Boosting* e *K-Nearest Neighbors* (KNN). Na aprendizagem não supervisionada, aplicou-se o algoritmo *K-Means*, sendo as métricas de validação (*accuracy* e matriz de confusão) também extraídas desta biblioteca.
- **Visualização de Dados:** As bibliotecas *Matplotlib* e *Seaborn* foram empregues na construção de toda a componente visual do estudo, sendo responsáveis pela geração de histogramas, *boxplots*, matrizes de confusão, gráficos de radar e projeções bidimensionais baseadas em Análise de Componentes Principais (PCA).

Como suporte complementar ao projeto, a plataforma *Kaggle* foi utilizada como repositório e fonte de acesso para a recolha do *dataset* original. Adicionalmente, utilizou-se o modelo de linguagem *Claude* (desenvolvido pela *Anthropic*) como ferramenta auxiliar de engenharia e programação, prestando apoio pontual na automatização do código técnico necessário para a fusão e consolidação dos ficheiros CSV originais num único conjunto de dados estruturado.

3.5 Técnicas

As técnicas analíticas aplicadas nesta investigação dividem-se em três pilares metodológicos complementares, selecionados em função da natureza das questões de investigação delineadas:

- **Estatística Inferencial Não-Paramétrica:**
  - *Teste de Shapiro-Wilk:* Utilizado para avaliar e comprovar estatisticamente a ausência de normalidade na distribuição da variável independente *valence*.
  - *Teste de Kruskal-Wallis:* Aplicado como alternativa não-paramétrica robusta à ANOVA para testar a equivalência das medianas de valência emocional entre os três grupos ordinais de popularidade.
  - *Matriz de Correlação Bivariada:* Técnica estatística utilizada para medir a força e a direção da associação linear direta entre as *audio features* contínuas e o índice de consumo.
- **Aprendizagem Supervisionada (Classificação):**
  - *Support Vector Classifier* (SVC): Algoritmo baseado em hiperplanos ótimos de separação, selecionado pelo seu desempenho robusto na classificação da popularidade das faixas em níveis (Baixa, Média e Alta).
  - *Discretização de Variáveis:* Técnica de transformação usada para converter a escala contínua de popularidade em categorias discretas organizadas.
  - *Engenharia de Atributos:* Métodos de combinação e agregação matemática de variáveis nativas para gerar novos preditores funcionais (*intensity* e *artist_avg_pop*).
- **Aprendizagem Não Supervisionada (Agrupamento e Redução de Dimensionalidade):**
  - *K-Means Clustering:* Algoritmo iterativo de partição baseado em distância euclidiana, aplicado para segmentar as 15 159 observações em $k = 6$ grupos homogéneos com base nos seus centroides de atributos áudio.

- *Método do Cotovelo e Índice de Silhueta:* Técnicas métricas de validação cruzada para estimar a coesão interna e a separação dos *clusters*, determinando o valor matemático ótimo para a partição.
- *Análise de Componentes Principais* (PCA): Técnica de transformação linear e redução de dimensionalidade utilizada para projetar o espaço multidimensional de 9 atributos num plano cartesiano bidimensional, facilitando a interpretação visual da distribuição dos *clusters*.

4 Resultados

Os resultados obtidos ao longo do presente trabalho permitem avaliar estatisticamente as diferenças entre os grupos considerados, avaliar o desempenho dos modelos desenvolvidos e identificar padrões relevantes nos dados analisados.

No que concerne à distribuição da variável dependente (*target*), a popularidade, a análise da Figura 1 permite observar que a maioria das faixas musicais se concentra numa faixa intermédia de consumo. O pico principal da distribuição (a moda) situa-se marcadamente entre os 40 e os 60 pontos. O comportamento dos dados desenha uma curva em formato de sino que se assemelha a uma distribuição normal, embora exiba uma ligeira assimetria à esquerda (assimetria negativa). Adicionalmente, verifica-se uma reduzida densidade de registos nos extremos absolutos da escala, demonstrando que a ocorrência de músicas com popularidade inferior a 20 ou superior a 80 pontos é um fenómeno marcadamente raro no ecossistema analisado.

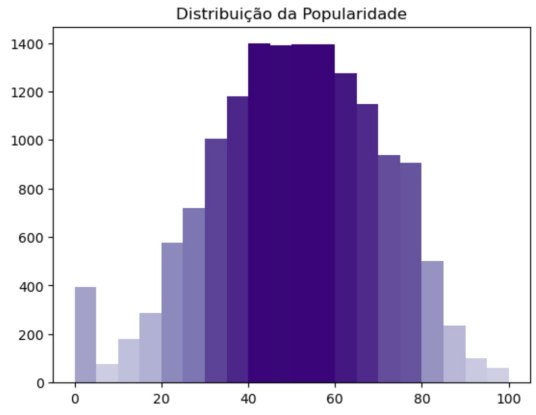


Figure 1. Distribuição da Popularidade.

No que diz respeito à análise comparativa entre os géneros musicais selecionados através do *boxplot*, a Figura 2 demonstra que, embora os três grupos exibam uma dispersão central e um comportamento que se sobrepõem na faixa intermédia de consumo, o bloco representativo do género *pop* encontra-se visivelmente deslocado para a direita da escala. Este comportamento evidencia que, apesar de registar um volume de produção potencialmente inferior a outros géneros na base de dados, o *pop* detém uma maior ressonância junto do público, revelando uma consistência superior no alcance de patamares elevados de popularidade.

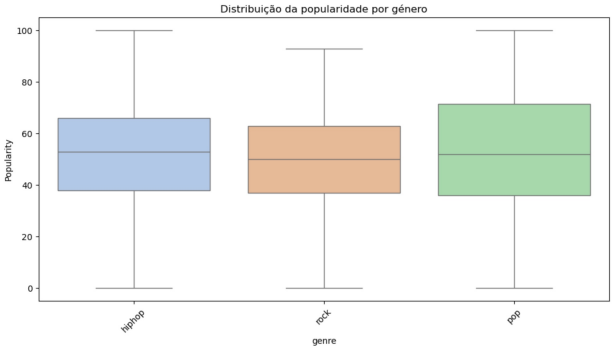


Figure 2. Distribuição da popularidade por género

Após a definição do enquadramento do negócio (*Business Understanding*), a fase de modelação iniciou-se com a análise da distribuição da variável independente *valence*. A inspeção visual, realizada através de um histograma e um gráfico de quantis teóricos (*Q-Q plot*), sugeriu inicialmente alguma simetria central, embora com desvios visíveis nas caudas, como é visível através da Figura 3.

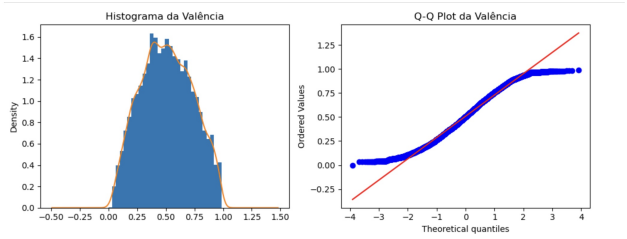


Figure 3. Histograma e *Q-Q plot*.

Contudo, a verificação formal através do teste de *Shapiro-Wilk* refutou esta observação, uma vez que o valor-p obtido foi inferior ao nível de significância de 5% ($p < 0,05$), confirmando a ausência de normalidade nos dados.

Dada a natureza não-paramétrica da distribuição, optou-se pela aplicação do Teste de *Kruskal-Wallis*. Para este procedimento, foi implementada uma técnica de subamostragem (*subsampling*) equilibrada, extraindo-se aleatoriamente 100 observações de cada nível de popularidade (Baixa, Média e Alta). A decisão de não utilizar a totalidade das 15.159 observações do *dataset* fundamenta-se na necessidade de evitar o fenómeno de inflação do valor-p, ou *large-sample bias*. Em bases de dados de grande dimensão ($n > 10.000$), a sensibilidade dos testes estatísticos é amplificada ao ponto de qualquer variação mínima — ainda que destituída de relevância prática ou artística — se tornar estatisticamente significativa ($p < 0,05$). Consequentemente, a utilização da totalidade da

amostra incorreria no risco de rejeitar a hipótese nula devido à dimensão do conjunto de dados, e não por uma disparidade real entre as distribuições.

A adoção do *subsampling* equilibrado assegurou três pilares metodológicos: a robustez, através da eliminação do ruído decorrente da disparidade no tamanho dos grupos; a relevância, permitindo aferir se a diferença observada é genuinamente impactante e não um artefacto matemático da dimensão do *dataset*; e a comparabilidade, estabelecendo um cenário de teste justo onde a uniformidade da dimensão amostral ($N = 100$ por grupo) elimina distorções na interpretação dos resultados.

O resultado do teste, com um valor-p de $0,397$, conduziu à não rejeição da hipótese nula (H_0). Estatisticamente, este resultado indica a inexistência de evidência suficiente para afirmar que a valência emocional difere significativamente entre os três níveis de popularidade. Em termos práticos, conclui-se que a distribuição da valência emocional é idêntica independentemente do sucesso comercial da obra, sugerindo que o estado emocional da música, isoladamente, não constitui um fator determinante na sua popularidade.

Adicionalmente, a análise do *boxplot* (Figura 4) confirma a ausência de diferenças significativas entre as médias dos grupos, evidenciando que a distribuição da valência emocional é homogénea nos diferentes patamares de popularidade.

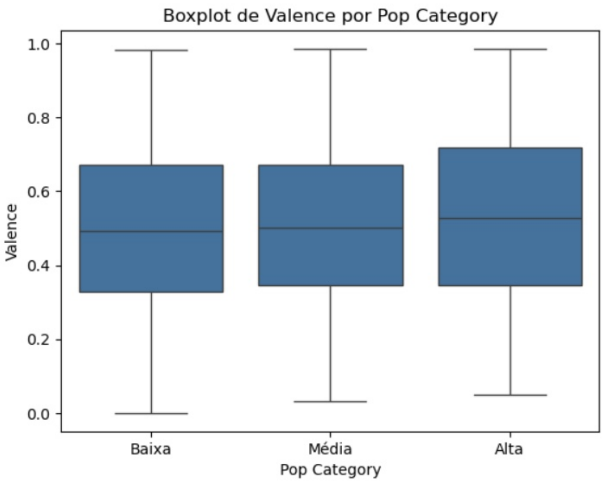


Figure 4. *Boxplot* da *valence* por `pop_category`

De forma a validar esta observação visual e a robustez do teste de hipóteses realizado, procedeu-se ao cálculo da correlação entre a variável *valence* e a popularidade das faixas musicais.

A matriz de correlação ilustrada na Figura 5 reforça a independência estatística entre o conteúdo emocional das faixas e o seu desempenho comercial, apresentando um coeficiente de correlação de Pearson de $r = 0,043$. Este valor, próximo de zero, atesta a inexistência de uma relação linear entre a valência emocional e o índice de consumo, confirmando os resultados obtidos através da análise inferencial anterior. Conclui-se, desta forma, que o estado emocional da composição não constitui um preditor relevante para o sucesso das faixas no ecossistema estudado, sendo a popularidade ditada por outros fatores extrínsecos.

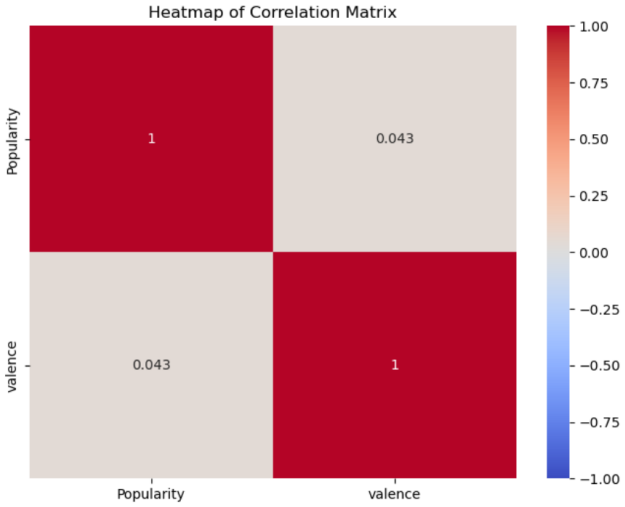


Figure 5. Matriz de correlação.

Estabelecida a relação entre valência e popularidade, a análise prosseguiu para a construção de modelos preditivos de classificação supervisionada.

No âmbito da modelação supervisionada, foram testados diferentes algoritmos de classificação. O modelo com melhor desempenho foi o *Support Vector Classifier* (SVC), atingindo uma *accuracy* de 81.135%, utilizando como *feature* a variável *artist_avg_pop* e como *target* a variável *pop_category*.

A Figura 6, evidencia uma forte sobreposição e direta entre as diferentes classes.

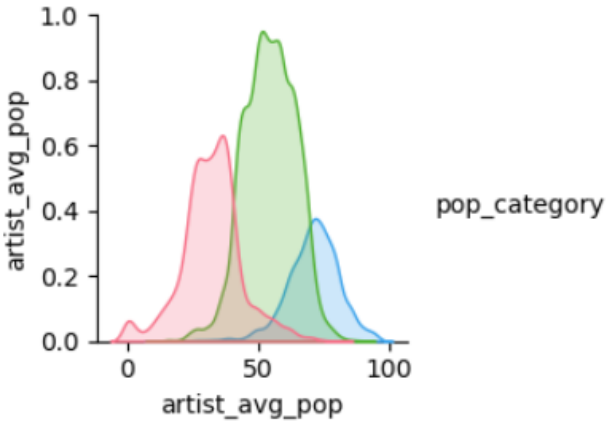


Figure 6. Distribuição da `artist_avg_pop` segmentada por `pop_category`.

O *pair plot* evidência que faixas classificadas na categoria `'Alta'` provêm, predominantemente, de artistas com um histórico de popularidade elevado, enquanto faixas com menor desempenho comercial estão associadas a artistas com menor notoriedade média. Este resultado mostra que a reputação e o alcance prévio do artista constituem os principais vetores de tração de uma nova música, superando largamente a influência de variáveis intrínsecas da composição, como o seu conteúdo emocional.

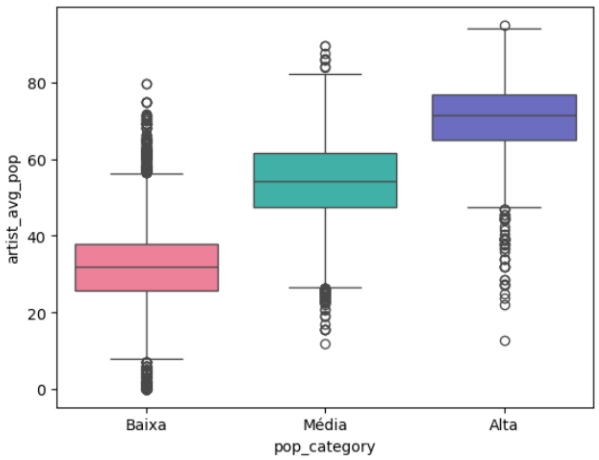


Figure 7. Distribuição da `artist_avg_pop` segmentada por `pop_category`.

O *boxplot*, Figura 7, mostra que valores mais baixos de *artist_avg_pop* estão associados à categoria de baixa popularidade, enquanto valores mais elevados se concentram nas categorias de média e alta popularidade. Observam-se ainda valores extremos (*outliers*) dentro de cada categoria.

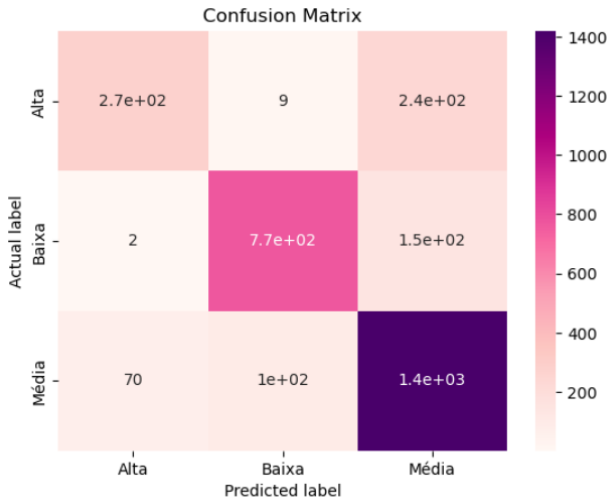


Figure 8. Matriz de confusão.

A análise da matriz de confusão (Figura 8) revela um desempenho assimétrico entre as categorias de popularidade. Verifica-se uma propensão do modelo em classificar incorretamente faixas das categorias `'Alta'` e `'Baixa'` como `'Média'`, fenómeno que sugere uma sobreposição nas características latentes destas classes.

Enquanto a classe `'Baixa'` apresenta uma robustez satisfatória, com uma baixa taxa de confusão com a classe `'Alta'`, a categoria `'Alta'` demonstra a maior vulnerabilidade, evidenciando que as fronteiras que definem o sucesso comercial de topo são menos nítidas do que aquelas que definem o insucesso. Este padrão reforça a interpretação de que o modelo tende a convergir para o centro da distribuição, indicando a dificuldade em isolar os preditores específicos que distinguem os êxitos comerciais dos restantes níveis de popularidade.

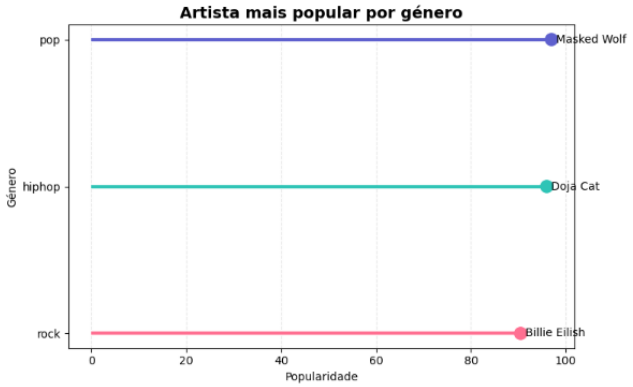


Figure 9. Artista mais popular por género.

No que diz respeito à análise dos artistas mais populares por género musical, como é visível a partir da Figura 9. No género *pop* destaca-se o artista *Masked Wolf*, com uma popularidade de 97. No género *hiphop*, a artista *Doja Cat* apresenta uma popularidade de 96. No género *rock*, a artista com maior popularidade é *Billie Eilish*, com um valor de 90.5.

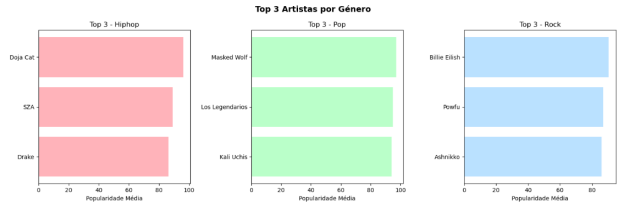


Figure 10. Top 3 Artistas mais popular por género.

O *top* 3 de artistas por género, Figura 10, inclui no *hiphop*, *Doja Cat*, *SZA* e *Drake*; no *pop*, *Masked Wolf*, *Los Legendarios* e *Kali Uchis*; no *rock*, *Billie Eilish*, *Powfu* e *Ashnikko*.

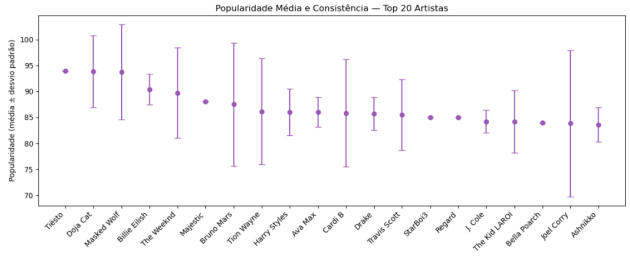


Figure 11. Top 20 Popularidade média dos artistas.

A Figura 11 de popularidade média e consistência dos artistas mostra que *Tiësto*, *Doja Cat* e *Masked Wolf* apresentam valores médios de popularidade superiores a 90. Artistas como *Bruno Mars*, *Tion Wayne*, *Cardi B* e *Joel Corry* apresentam maior dispersão nos valores de popularidade. Artistas como *Majestic*, *StarBoi3*, *Bella Poarch*, *Regard* e *J. Cole* apresentam menor dispersão.

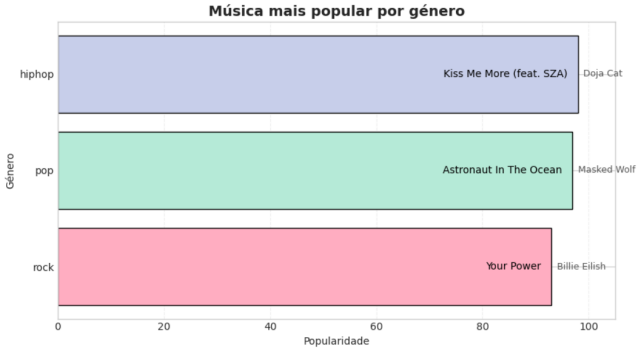


Figure 12. Música mais popular por género.

Relativamente às músicas mais populares por género, Figura 12, no *hiphop* a música mais popular é "Kiss Me More" de *Doja Cat*, com uma popularidade de 98. No *pop*, destaca-se "Astronaut in the Ocean" de *Masked Wolf*, com uma popularidade de 97. No *rock*, a música mais popular é "Your Power" de *Billie Eilish*, com um valor de 93.

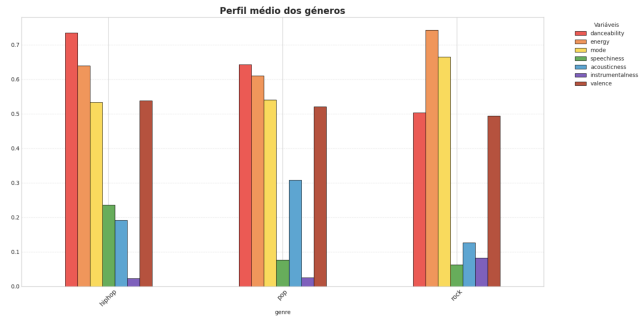


Figure 13. Perfil médio por género.

A Figura 13, perfil médio dos géneros, mostra que o género *rock* apresenta valores mais elevados na variável *energy*. Os géneros *hiphop* e *pop* apresentam valores mais elevados de *danceability*. As variáveis *acousticness* e *instrumentalness* apresentam valores reduzidos nos três géneros. A variável *valence* apresenta valores próximos entre os três géneros.

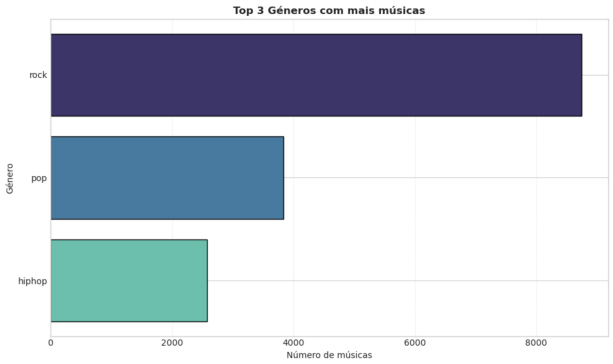


Figure 14. Top 3 Género com mais músicas.

A Figura 14 apresenta uma distribuição desigual entre as três categorias analisadas. O género *rock* apresenta o maior número de faixas, com 8 747 músicas. O género *pop* contém 3 831 faixas, e o género *hiphop* regista o menor número de observações, com 2 581 faixas.

Por último, passando para a aprendizagem não supervisionada, o *dataset* é composto por 15 159 faixas distribuídas por três géneros: *rock* (8 747 faixas), *pop* (3 831 faixas) e *hiphop* (2 581 faixas), sem valores nulos, como se observa pela Figura 15.

```
── Avaliação de k (3 a 9) ──
  k |    Inércia | Silhouette | Davies-Bouldin
-------------------------------------------------
  3 |     102643 |     0.1534 |         1.9849
  4 |      91118 |     0.1674 |         1.7553
  5 |      82171 |     0.1663 |         1.6711
  6 |      76274 |     0.1725 |         1.5837
  7 |      71507 |     0.1635 |         1.5763
  8 |      68091 |     0.1563 |         1.5601
  9 |      65599 |     0.1447 |         1.5886

── Perfis de Ouvinte Identificados ──
  [0] Acústica              →  2435 faixas (16.1%)
  [1] Energia ao Vivo       →  1302 faixas (8.6%)
  [2] Instrumental          →   925 faixas (6.1%)
  [3] Pop                   →  4632 faixas (30.6%)
  [4] Hip-Hop               →  1804 faixas (11.9%)
  [5] Rock                  →  4061 faixas (26.8%)

============================================================
SUMÁRIO DO MODELO
============================================================
  Algoritmo      : K-Means  (k=6)
  Features       : 9
  Faixas totais  : 15,159
  Silhouette     : 0.1725
  Davies-Bouldin : 1.5837  (↓ melhor)

  Perfis identificados:
    [0] Acústica              —  2435 faixas | género dominante: pop
    [1] Energia ao Vivo       —  1302 faixas | género dominante: rock
    [2] Instrumental          —   925 faixas | género dominante: rock
    [3] Pop                   —  4632 faixas | género dominante: rock
    [4] Hip-Hop               —  1804 faixas | género dominante: hiphop
    [5] Rock                  —  4061 faixas | género dominante: rock
```

Figure 15. Clusters.

Para a análise de *clustering*, foram avaliados valores de k entre 3 e 9. O valor $k = 6$ registou um *Silhouette Score* de 0.1725 e um índice de *Davies-Bouldin* de 1.5837. Foram identificados seis perfis de ouvinte: Acústica (16.1%), Energia ao Vivo (8.6%), Instrumental (6.1%), *Pop* (30.6%), *Hip-Hop* (11.9%) e *Rock* (26.8%).

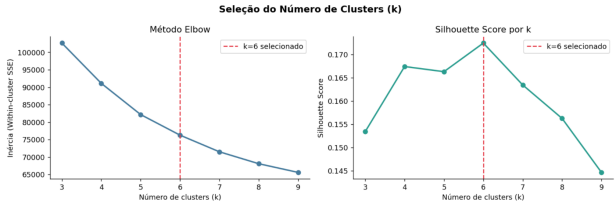


Figure 16. Seleção no número de clusters.

A análise do método *Elbow* (Figura 16) apresentou uma redução gradual da inércia à medida que o número de *clusters* aumenta, sem exibir um ponto de inflexão claramente definido que indique, por si só, o número ótimo de grupos. Dada esta ambiguidade, recorreu-se ao *Silhouette Score* (Figura 16) como critério de validação complementar. Esta métrica atingiu o seu valor máximo para $k = 6$, evidenciando uma melhor separação e coesão dos *clusters* neste nível. Consequentemente, a convergência entre a estabilidade sugerida pela curva de inércia e a otimização da métrica de silhueta valida a escolha de $k = 6$ como o parâmetro mais equilibrado para a segmentação, assegurando que os grupos resultantes são distintos e internamente coerentes.

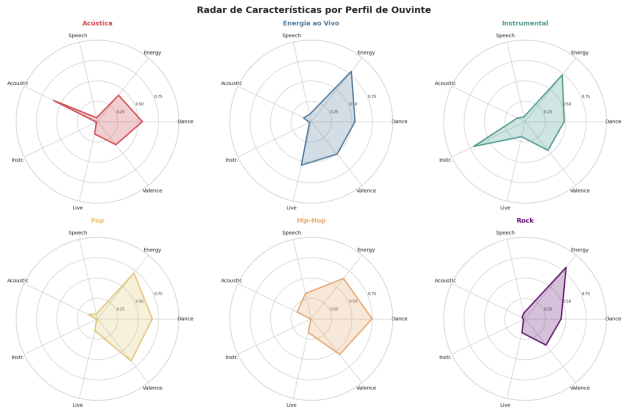


Figure 17. Radar de características por perfil de ouvinte.

A análise dos *radar charts*, Figura 17, mostra que o perfil Acústica apresenta valores elevados de *acousticness*. O perfil Energia ao Vivo apresenta valores elevados de *energy* e *liveness*. O perfil Instrumental apresenta valores elevados de *instrumentalness*. O perfil *Pop* apresenta valores elevados de *danceability* e *valence*. O perfil *Hip-Hop* apresenta valores elevados de *speechiness*. O perfil *Rock* apresenta valores elevados de *energy* e valores reduzidos de *acousticness*.

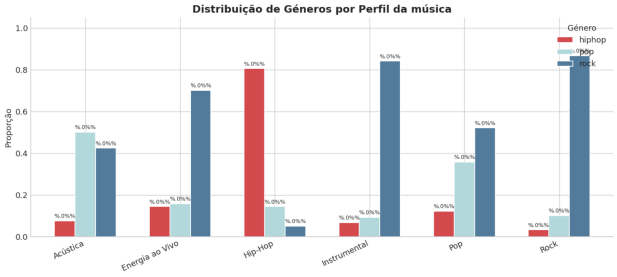


Figure 18. Distribuição de géneros por perfil de ouvinte.

A análise da distribuição de géneros por perfil , Figura 18, que o *cluster Hip-Hop* apresenta aproximadamente 80% de músicas deste género.

O *cluster Rock* apresenta uma predominância de *rock*, com valores próximos de 87%. Os *clusters* Instrumental e Energia ao Vivo são dominados pelo género *rock*. Os *clusters Pop* e Acústica apresentam uma distribuição mais equilibrada entre géneros.

Por último, a Figura 19, representa 38.9% da variância total dos dados, sendo 20.8% explicada pelo PC1 e 18.1% pelo PC2.

O PC1 pode ser interpretado como um eixo de dançabilidade vs. tonalidade estruturada, dado que as variáveis com maior peso positivo são a *danceability* (0.596) e a *acousticness* (0.297), enquanto as variáveis com maior peso negativo são a *key* (-0.538) e a *Popularity* (-0.390). Músicas com valores elevados de PC1 tendem a ser mais dançáveis e acústicas; músicas com valores negativos tendem a ter uma estrutura tonal mais definida e maior popularidade.

O PC2 representa um eixo de expressividade vocal vs. energia, sendo dominado positivamente pela *speechiness* (0.547) e pela *Popularity* (0.510), e negativamente pela *key* (-0.303). Valores elevados de PC2 correspondem a músicas com maior presença vocal e popularidade, independentemente da sua energia.

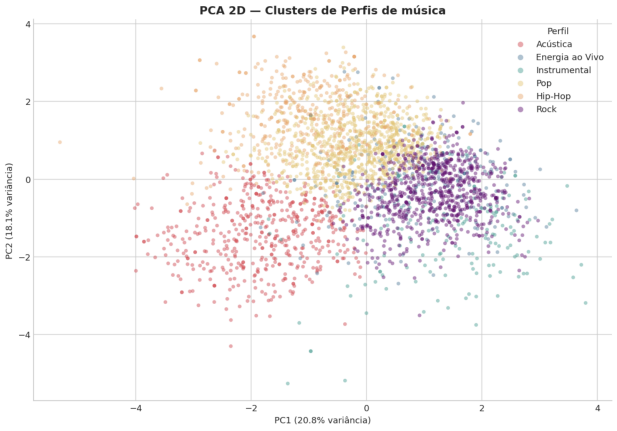


Figure 19. PCA 2D

A projeção evidencia que o perfil Acústica se posiciona predominantemente nos valores negativos do PC1, enquanto o perfil Rock se concentra nos valores positivos. Os perfis Pop e Hip-Hop apresentam uma distribuição centrada no gráfico, com alguma sobreposição entre si. Os perfis Instrumental e Energia ao Vivo encontram-se dispersos ao longo do eixo PC2.

5 Discussão

5.1 Valência e Popularidade Musical

A primeira questão de investigação propunha avaliar em que medida a valência emocional de uma faixa se correlaciona com o seu nível de popularidade. Os resultados obtidos indicam que essa relação não é estatisticamente significativa no contexto analisado. O teste de Kruskal-Wallis, aplicado a uma amostra equilibrada de 100 observações por grupo de popularidade, devolveu um p-value de 0,397 (acima do limiar de significância de 5%), conduzindo à não rejeição da hipótese nula (H0). Este resultado foi confirmado pela análise visual dos boxplots (Figura 4), que revelou sobreposição considerável das distribuições de valência entre os três grupos de popularidade (Baixa, Média e Alta), e pela matriz de correlação de Pearson (Figura 5), cujo coeficiente r = 0,043 mostra a ausência de associação linear relevante entre as duas variáveis. A normalidade da variável valence foi previamente avaliada através do histograma e Q-Q plot (Figura 3), tendo o teste de Shapiro-Wilk confirmado a sua ausência, o que justificou a opção pelo teste não-paramétrico.

Estes resultados alinham-se parcialmente com a literatura existente. Embora [3] e [4] tenham demonstrado que a valência e a energia são proxies computacionais válidos das dimensões emocionais da música, o presente estudo sugere que o conteúdo emocional de uma faixa, quando considerado isoladamente, não constitui um preditor relevante do seu desempenho comercial. Esta conclusão é consistente com [8], que evidenciou que os audio features por si só capturam apenas parcialmente os fatores determinantes do sucesso musical, sendo a dimensão social (nomeadamente a notoriedade prévia do artista) um complemento indispensável.

Importa, todavia, reconhecer uma limitação metodológica inerente à opção pelo subsampling equilibrado. A decisão de trabalhar com 100 observações por grupo, em detrimento das 15 159 faixas disponíveis, teve como objetivo explícito mitigar o fenómeno de large-sample bias — situação em que, em bases de dados de grande dimensão, qualquer diferença mínima se torna estatisticamente significativa independentemente da sua relevância prática. Contudo, esta escolha implica que a aceitação da hipótese nula se fundamenta numa amostra reduzida e não no dataset completo, o que limita a generalização do resultado. Com uma amostra diferente ou um limiar de subsampling distinto, os resultados poderiam, em teoria, divergir. A replicabilidade do teste foi assegurada através da fixação de uma semente aleatória (seed = 42), garantindo a reprodutibilidade dos resultados, mas não eliminando a incerteza associada à dimensão amostral reduzida.

5.2 Modelos Preditivos de Popularidade

No âmbito da modelação supervisionada, o Support Vector Classifier (SVC) destacou-se como o algoritmo com melhor desempenho preditivo, atingindo uma acurácia de 81,13% quando treinado com a variável derivada artist_avg_pop como principal preditor da categoria de popularidade. Este resultado converge com a literatura: [7] obteve 69% de acurácia com Random Forest, utilizando exclusivamente audio features nativos do Spotify, enquanto [5] atingiu 95,37% com um dataset de escala significativamente superior (mais de 170 000 faixas). A diferença de desempenho entre estes estudos sublinha a elevada sensibilidade dos modelos preditivos à composição do dataset e às variáveis explicativas disponíveis.

A variável artist_avg_pop (calculada como a média histórica de popularidade das faixas de cada artista) revelou-se o preditor mais robusto, superando largamente o poder discriminativo dos audio features intrínsecos à composição, incluindo a valência. Este resultado reforça a interpretação de que o sucesso comercial de uma nova música depende, em larga medida, da notoriedade do artista, funcionando como um efeito de reputação que antecede e condiciona a receção de qualquer nova obra. Tal achado está alinhado com [8], que demonstrou que a incorporação de variáveis de carácter social e contextual melhora significativamente a precisão dos modelos de previsão de popularidade.

A análise da matriz de confusão (Figura 8) revelou um padrão assimétrico de erros: o modelo demonstrou maior dificuldade em classificar corretamente faixas de popularidade "Alta", confundindo-as frequentemente com a categoria "Média". Esta sobreposição nas fronteiras entre classes sugere que os preditores disponíveis não capturam integralmente os fatores que distinguem os êxitos comerciais de topo. A separação visual entre categorias, evidenciada na Figura 6 e no boxplot da Figura 7, confirma que a artist_avg_pop discrimina bem as classes extremas, mas apresenta maior ambiguidade na fronteira entre "Média" e "Alta". Fatores extrínsecos não modelizados, como o investimento em marketing, a sincronização em plataformas de vídeo ou o momento de lançamento, poderão explicar parte desta variância residual.

5.3 Análise Exploratória por Género e Artistas

A análise exploratória por género revelou que o pop apresenta consistentemente os valores medianos de popularidade mais elevados, como se observa no boxplot da Figura 2. Ainda que o rock corresponda ao género com maior número de faixas no dataset (8 747, face a 3 831 de pop e 2 581 de hip-hop), conforme ilustrado na Figura 14, este desequilíbrio de volume não se traduz numa vantagem em termos de popularidade. Este resultado sugere que a popularidade não é necessariamente proporcional ao volume de produção, indicando

antes uma maior eficiência comercial do pop no contexto das playlists analisadas. O desequilíbrio na distribuição de faixas entre géneros é igualmente uma limitação a considerar na interpretação dos resultados comparativos, uma vez que o rock está sobrerrepresentado em termos absolutos face ao hip-hop.

No que respeita ao perfil médio dos géneros (Figura 13), o rock destacou-se pelos valores mais elevados de energy, enquanto o hip-hop e o pop apresentaram maior danceability. A variável valence evidenciou valores próximos entre os três géneros, o que é consistente com a ausência de diferenças significativas na análise inferencial prévia. Estes perfis comprovam as caracterizações propostas por [4], que identificou a energia e a dançabilidade como as dimensões acústicas mais diferenciadas entre géneros.

A nível individual, os líderes de popularidade por género foram Masked Wolf no pop ("Astronaut in the Ocean", popularidade 97), Doja Cat no hip-hop ("Kiss Me More", popularidade 98) e Billie Eilish no rock ("Your Power", popularidade 93), como evidenciado nas Figuras 9 e 12. O top 3 por género (Figura 10) reforça a consistência destes artistas, com Doja Cat, SZA e Drake no hip-hop; Masked Wolf, Los Legendarios e Kali Uchis no pop; e Billie Eilish, Powfu e Ashnikko no rock. A consistência destes artistas no topo das classificações reforça a ideia de que a notoriedade estabelecida funciona como um fator autorreforçador do sucesso comercial.

A análise do top 20 de popularidade média e consistência dos artistas (Figura 11) acrescenta uma dimensão importante a esta leitura. Tiësto, Doja Cat e Masked Wolf destacam-se com valores médios de popularidade superiores a 90, evidenciando uma performance comercial estruturalmente elevada. Em contraste, artistas como Bruno Mars, Tion Wayne, Cardi B e Joel Corry apresentam maior dispersão nos valores de popularidade, o que sugere uma trajetória menos estável — possivelmente associada a lançamentos com desempenhos mais variáveis. Esta distinção entre artistas de alta média e alta consistência versus artistas de alta média, mas elevada dispersão tem implicações práticas relevantes: o preditor artist_avg_pop captura a média histórica, mas não a variabilidade, o que pode introduzir imprecisão na classificação de artistas com carreiras irregulares.

Outro aspeto a considerar é o desequilíbrio no volume de faixas entre géneros (Figura 14). O rock representa 57,7% do dataset (8 747 faixas), o pop 25,3% (3 831) e o hip-hop apenas 17% (2 581). Esta assimetria pode influenciar os modelos de clustering — onde géneros com maior representação tendem a dominar mais clusters — e os resultados comparativos entre géneros, uma vez que a maior diversidade interna do rock resulta de uma amostragem mais alargada e não necessariamente de uma maior heterogeneidade intrínseca ao género.

5.4 Segmentação por Clustering e Perfis de Ouvinte

A aplicação do algoritmo K-Means permitiu identificar seis perfis comportamentais distintos no espaço de nove atributos acústicos: Acústica (16,1%), Energia ao Vivo (8,6%), Instrumental (6,1%), Pop (30,6%), Hip-Hop (11,9%) e Rock (26,8%), conforme detalhado na Figura 15. A seleção de k = 6 foi fundamentada pela maximização do Silhouette Score (0,1725) e pela minimização do índice Davies-Bouldin (1,5837), sendo suportada graficamente pela análise conjunta do Método Elbow e do Silhouette Score por k (Figura 16). Embora o valor de Silhouette Score seja modesto, refletindo a sobreposição natural entre géneros musicais no espaço de features contínuas, os perfis obtidos apresentam coerência interpretativa e correspondência com categorias reconhecíveis no mercado musical.

A análise dos radar charts (Figura 17) e da distribuição de géneros por perfil (Figura 18) evidenciou uma correspondência lógica entre as características acústicas dos clusters e os géneros que os dominam: o cluster Hip-Hop concentra cerca de 80% de músicas desse género, destacando-se pelos valores mais elevados de speechiness; o cluster Rock é dominado a 87% pelo rock, com energia elevada e acousticness reduzida; o cluster Acústica apresenta alta acousticness e uma distribuição mais equilibrada entre géneros. Estes resultados validam a capacidade do algoritmo de capturar uma estrutura latente nos dados de forma não supervisionada.

A projeção bidimensional via Análise de Componentes Principais (Figura 19), que explica 38,9% da variância total (PC1: 20,8%; PC2: 18,1%), complementou a validação visual dos clusters, confirmando a separação dos perfis no espaço reduzido. O perfil Acústica posiciona-se predominantemente nos valores negativos do PC1, enquanto o Rock concentra-se nos valores positivos; os perfis Pop e Hip-Hop apresentam uma distribuição centrada com alguma sobreposição entre si. A interpretação dos eixos principais — PC1 como eixo de dançabilidade vs. tonalidade estruturada e PC2 como eixo de expressividade vocal vs. energia — é consistente com as dimensões emocionais identificadas por [6] no modelo circumplexo do afeto.

6 Conclusão

6.1 Síntese dos Resultados e Contributos

O presente trabalho procurou responder à questão central: em que medida as características de uma faixa, em particular a valência, influenciam a sua popularidade, e que padrões emergem quando se analisam artistas, músicas e perfis de ouvintes nos géneros pop, hip-hop e rock? Os resultados obtidos permitem formular respostas fundamentadas a esta questão.

Em primeiro lugar, a valência emocional, isoladamente, não é um fator determinante da popularidade musical no contexto analisado. O teste de Kruskal-Wallis com subsampling equilibrado confirmou a não rejeição de H0 (p = 0,397),

e a correlação de Pearson entre valência e popularidade (r = 0,043) reforça a independência estatística entre as duas variáveis. Este resultado contraria a intuição de que músicas mais alegres ou emocionalmente positivas teriam, por si só, maior aceitação comercial.

Em segundo lugar, o preditor com maior poder discriminativo para a popularidade revelou ser a variável artist_avg_pop, que sustentou uma acurácia de 81,13% no modelo SVC. Este resultado aponta para um fenómeno de capital de reputação: artistas com historial de sucesso tendem a ver as suas novas faixas classificadas em patamares de popularidade mais elevados, independentemente das características acústicas da composição.

Em terceiro lugar, a análise exploratória por género confirmou a maior eficiência comercial do pop, que detém os valores medianos de popularidade mais elevados apesar de corresponder a um volume de produção inferior ao do rock no dataset. Os artistas líderes de popularidade por género — Masked Wolf (pop), Doja Cat (hip-hop) e Billie Eilish (rock) — evidenciam trajetórias de notoriedade consistentes, corroborando o efeito de reputação identificado na modelação preditiva.

Por último, a segmentação por K-Means (k = 6) revelou perfis comportamentais com interpretação musical coerente, permitindo mapear nichos de consumo distintos no mercado: do ouvinte de acústica ao fã de energia ao vivo, passando pelo público pop/dançável e pelos consumidores de hip-hop e rock. Estes perfis constituem uma ferramenta operacional com potencial aplicação em sistemas de recomendação e criação de playlists.

6.2 Limitações

O presente trabalho apresenta um conjunto de limitações que devem ser consideradas na interpretação dos resultados.

Em primeiro lugar, o subsampling e a generalização da hipótese nula. A aceitação de H0 relativamente à valência foi obtida com base numa amostra de apenas 100 observações por grupo de popularidade, e não no dataset completo de 15 159 faixas. Embora esta opção metodológica tenha sido feita com o objetivo de mitigar o large-sample bias, implicou que a conclusão sobre a ausência de relação entre valência e popularidade fosse tecnicamente condicionada pela dimensão e composição da amostra utilizada. Com amostras distintas, os resultados poderiam variar.

Em segundo lugar, a exclusividade de audio features. O dataset utilizado assenta exclusivamente em descritores acústicos quantitativos disponibilizados pelo Spotify, não incorporando fatores contextuais com impacto comprovado na popularidade, como a presença nas redes sociais, a exposição mediática ou o momento de lançamento. Esta limitação, partilhada em grande parte da literatura [8], compromete a capacidade explicativa dos modelos desenvolvidos.

Em terceiro lugar, a qualidade do clustering. O valor de Silhouette Score de 0,1725 é modesto, refletindo a sobreposição natural entre géneros no espaço de features contínuas. Os clusters obtidos são interpretáveis, mas não apresentam uma separação nítida, o que limita a sua utilidade como ferramenta de segmentação de precisão.

Em quarto lugar, a ausência de análise temporal. O dataset utilizado é estático, correspondendo a um único momento de recolha. A popularidade das faixas e dos artistas é, contudo, um fenómeno intrinsecamente dinâmico — artistas em ascensão ou em declínio apresentam trajetórias distintas que uma análise estática não consegue capturar. Esta limitação tem implicações diretas na variável artist_avg_pop, cujo valor reflete um estado fixo e não a evolução da notoriedade do artista ao longo do tempo. A relevância desta dimensão temporal é reconhecida na literatura — [8] evidencia que fatores dinâmicos, como o crescimento de seguidores em redes sociais, têm impacto significativo na popularidade musical — o que reforça a necessidade de incorporar uma perspetiva longitudinal em investigações futuras.

Por último, a cobertura limitada de géneros musicais. A análise restringe-se a três géneros (pop, rock e hip-hop), o que limita a generalização das conclusões ao mercado musical mais alargado. É plausível que as relações entre audio features e popularidade, bem como os perfis de ouvinte identificados, apresentem padrões distintos noutros géneros, pelo que os resultados aqui obtidos devem ser interpretados como válidos para o contexto específico analisado e não como conclusões universais sobre a indústria musical.

6.3 Trabalhos Futuros

Os resultados e limitações identificados apontam para várias direções de investigação futura. Em primeiro lugar, a integração de variáveis externas, como métricas de redes sociais (número de streams no YouTube, seguidores no Instagram, menções no TikTok) ou dados de cobertura mediática, permitiria desenvolver modelos mais completos e com maior poder preditivo, respondendo à lacuna identificada por [8]. Em segundo lugar, a aplicação de técnicas de deep learning — nomeadamente redes neurais convolucionais sobre espetrogramas de áudio — poderia capturar dimensões sonoras não contempladas pelos audio features pré-computados do Spotify, aproximando a análise da experiência percetiva real do ouvinte. Em terceiro lugar, a extensão da análise a géneros musicais não contemplados (jazz, eletrónica, etc) e a mercados geográficos distintos permitiria avaliar a generalização dos padrões identificados. Por último, acompanhar as mesmas faixas ao longo do tempo permitiria perceber como a popularidade evolui, contribuindo para uma compreensão mais aprofundada dos mecanismos de ascensão e declínio de artistas nas plataformas de streaming.

References

[1] Hareesh Bahuleyan. 2018. Music genre classification using machine learning techniques. *arXiv preprint arXiv:1804.01149* (2018).

[2] Mousumi Chaudhury, Amin Karami, and Mustansar Ali Ghazanfar. 2022. Large-scale music genre analysis and classification using machine learning with apache spark. *Electronics* 11, 16 (2022), 2567.

[3] Deniz Duman, Pedro Neto, Anastasios Mavrolampados, Petri Toiviainen, and Geoff Luck. 2022. Music we move to: Spotify audio features and reasons for listening. *Plos one* 17, 9 (2022), e0275228.

[4] Shruti Dutta and Shashwat Mookherjee. 2023. Exploring the emotional landscape of music: An analysis of valence trends and genre variations in spotify music data. *arXiv preprint arXiv:2310.19052* (2023).

[5] Joshua S Gulmatico, Julie Ann B Susa, Mon Arjay F Malbog, Aimee Acoba, Marte D Nipas, and Jennalyn N Mindoro. 2022. SpotiPred: A machine learning approach prediction of Spotify music popularity by audio features. In *2022 Second International Conference on Power, Control and Computing Technologies (ICPC2T)*. IEEE, 1–5.

[6] James A Russell. 1980. A circumplex model of affect. *Journal of personality and social psychology* 39, 6 (1980), 1161.

[7] Harriman Samuel Saragih. 2023. Predicting song popularity based on Spotify's audio features: insights from the Indonesian streaming users. *Journal of Management Analytics* 10, 4 (2023), 693–709.

[8] Yap Kah Yee and Mafas Raheem. 2022. Predicting music popularity using spotify and youtube features. *Indian Journal of Science and Technology* 15, 36 (2022), 1786–1799.

A Appendices

```
Tenho 3 datasets quero junt -los e criar uma nova
     coluna como respetivo g nero (que ser o pop
    , hiphop ou rock). A ferramenta ultilizada foi
     o Claude
```